

AnalystLab Africa — Experience Lab

HealthConnect Analytics Testing & Refinement

Systematic Testing, Validation & Evidence-Based Refinement

Piste : Data Analytics — Semaine 7

1. Transition Semaine 6 → Semaine 7

Cette section établit brièvement le lien avec la Semaine 6, sans en reproduire le contenu (voir HealthConnect_Advanced_Analytics_Report.docx pour le détail complet).

Principal output Semaine 6	Validation statistique des KPIs (χ^2), segmentation de risque à 4 niveaux, modèle de validation prédictive (62,4% accuracy)
Résultat le plus important	Effet combiné délai $\times$ historique confirmé jusqu'à 91% de no-show ; modèle validé (+11,3 pts vs baseline naïve)
Limite/dépendance identifiée	Cellule '0-7j $\times$ 3+' non expliquée (23%, contre-intuitive) ; performance du modèle non décomposée par segment
Composant à tester cette semaine	Exactitude des KPIs publiés, fiabilité de la heatmap combinée, comportement du modèle de classification par segment
Piste concernée	Data Science (test de l'intégration réalisée en Semaine 6)
Objectif Semaine 7	Confirmer que les KPIs publiés sont exacts, déterminer si l'anomalie de la heatmap est un vrai signal ou du bruit, et tester si le modèle échoue de façon disproportionnée sur un segment de risque particulier

2. Préparation des Tests (Part 1 du cahier des charges)

2.1 Composant testé

Les sorties analytiques de la Semaine 5-6 : les 4 KPIs publiés (délai de réservation, historique de no-shows, canal de rappel, distance), la heatmap combinée (effet délai $\times$ historique), et le modèle de classification construit comme preuve d'intégration cross-track.

2.2 Objectif du test

Déterminer si (1) les valeurs numériques publiées dans les rapports précédents sont exactes et reproductibles, (2) les résultats analytiques restent valides face à un examen statistique plus rigoureux, et (3) le modèle de classification se comporte de façon fiable et cohérente à travers les segments de risque identifiés par l'analyse Data Analytics.

3. Journal de Tests

Test/Scénario	Résultat Attendu	Résultat Réel	Pass/Fail	Problème Identifié	Action Prise	Résultat Retest
Recalcul indépendant des 4 KPIs publiés (S5-S6)	Correspondance exacte avec les valeurs publiées	100% de correspondance sur les 13 valeurs testées (délai, historique, canal)	PASS	Aucun	Aucune (validation confirmée)	N/A
Cellule heatmap '0-7j × 3+ no-shows' (23%)	Cohérence avec la tendance générale croissante	23%, en rupture apparente avec la tendance (attendu ~50-60%)	FAIL (investigation)	Anomalie potentielle sur petit échantillon (n=13)	Test statistique (IC de Wilson à 95%) + annotation n sur la heatmap	IC=[8,2%;50,3%] — bruit d'échantillonnage confirmé, pas un vrai signal ; heatmap corrigée avec annotations n
Erreurs du modèle Semaine 6 par segment de risque	Erreurs réparties uniformément entre segments	Faux négatifs concentrés à 34,3% sur le segment 'Low Risk' vs 0% sur 'High Risk'	FAIL	Seuil de décision (0,50) trop conservateur pour capturer les no-shows en zone 'Low Risk'	Abaissement du seuil de classification à 0,40	Faux négatifs 'Low Risk' réduits à 24,1% (F1 global amélioré de 0,652 à 0,686)

4. Test 1 — Validation des Calculs KPI

Les 4 KPIs publiés en Semaine 5-6 (délai de réservation, historique de no-shows, canal de rappel, taux global) ont été recalculés indépendamment à partir du dataset nettoyé, sans réutiliser le code original, pour détecter toute erreur de calcul ou de report qui aurait pu se glisser dans les rapports précédents.

Résultat : les 13 valeurs testées (taux global + 5 tranches de délai + 4 tranches d'historique + 4 canaux de rappel) correspondent exactement aux valeurs publiées (écart maximal de 0,05 point de pourcentage, imputable à l'arrondi). Ce test valide la fiabilité de l'ensemble des KPIs utilisés dans les recommandations business des semaines précédentes.

5. Test 2 — Investigation de l'Anomalie Statistique

La heatmap combinée de la Semaine 6 (délai × historique) présentait une cellule contre-intuitive : les rendez-vous avec un délai court (0-7 jours) ET un historique de 3+ no-shows affichaient un taux de no-show de seulement 23% — inférieur à la cellule voisine (8-14 jours × 3+, à 60%), ce qui rompait la tendance croissante attendue.

- Taille de l'échantillon concerné : n=13 (3 no-shows sur 13 rendez-vous)
- Intervalle de confiance de Wilson à 95% : [8,2% ; 50,3%]
- Test binomial contre une proportion de référence de 50% : p = 0,092 (non significatif)

Conclusion validée : l'intervalle de confiance est si large qu'il est statistiquement compatible avec des valeurs bien plus élevées (jusqu'à 50%), cohérentes avec la tendance générale. Ce résultat est donc du bruit d'échantillonnage sur un petit groupe, pas un véritable retournement de tendance.




Figure 9 : Heatmap raffinée avec annotations de taille d'échantillon

Action de raffinement : toutes les cellules reposant sur moins de 30 observations sont désormais marquées d'un astérisque avec leur taille d'échantillon affichée, pour éviter toute interprétation business erronée sur des cellules statistiquement fragiles. La segmentation de risque à 4 niveaux utilisée pour les recommandations (Semaine 6) repose sur des groupes bien plus larges (237 à 348 observations chacun) et n'est donc pas affectée par ce problème.

6. Test 3 — Analyse d'Erreur du Modèle (Intégration Cross-Track Obligatoire)

Piste concernée : Data Science. Dépendance testée : le modèle de classification construit en Semaine 6 comme preuve d'intégration (4 KPIs Data Analytics utilisés comme features).

Test réalisé : plutôt que de se contenter du score global (62,4% d'accuracy, déjà établi en Semaine 6), les erreurs du modèle ont été décomposées par segment de risque défini par l'analyse Data Analytics, afin de vérifier si le modèle échoue de façon homogène ou concentrée.

Trouvaille : le modèle ne manque jamais un patient 'High Risk' (0% de faux négatifs sur ce segment) mais rate 34,3% des vrais no-shows du segment 'Low Risk' — le seuil de décision par défaut (0,50) est trop conservateur pour ce segment, où le taux de base de no-show (34,5%) reste pourtant loin d'être négligeable.

Action de raffinement : le seuil de classification a été abaissé de 0,50 à 0,40, un ajustement justifié par l'asymétrie des coûts métier (un no-show manqué coûte un créneau perdu, plus coûteux qu'un rappel préventif envoyé à tort).




Figure 10 : Taux de faux négatifs par segment de risque, avant/après raffinement du seuil

Retest : après abaissement du seuil à 0,40, le taux de faux négatifs sur 'Low Risk' passe de 34,3% à 24,1%, et sur 'Medium Risk (history)' de 21,9% à 10,1%, sans dégrader le segment 'High Risk' (toujours 0%). Le F1-score global s'améliore de 0,652 à 0,686 (recall 0,690 → 0,828), au prix d'une légère baisse d'accuracy (62,4% → 61,3%) et de précision — un compromis jugé favorable étant donné le coût plus élevé d'un no-show manqué.

Ce qui a changé grâce à cette intégration : la piste Data Analytics a fourni la segmentation de risque qui a permis de détecter un défaut invisible au niveau du score global du modèle (une faiblesse spécifique au segment 'Low Risk'), et la piste Data Science (auto-assumée) a livré en retour un modèle recalibré et retesté — un véritable cycle Test → Trouvaille → Action → Retest → Amélioration validée.

7. Recommandations Mises à Jour

1. Adopter le seuil de classification à 0,40 (et non 0,50) pour tout usage opérationnel du modèle de no-show — Ce réglage réduit significativement les no-shows non anticipés dans les segments Low et Medium Risk, avec un compromis d'accuracy jugé acceptable au vu du coût métier asymétrique.
2. Ne pas construire de règles business sur les cellules de la heatmap combinée marquées d'un astérisque ($n < 30$) — Utiliser exclusivement la segmentation de risque à 4 niveaux (Semaine 6), dont les groupes sont suffisamment larges pour être fiables.
3. Maintenir un rappel standard même pour les patients 'Low Risk' — Le test d'erreur confirme que ce segment conserve un taux de no-show non négligeable (34,5%) et que le modèle, même raffiné, continue d'en manquer environ un quart ; aucune désactivation de rappel ne doit être envisagée sur ce segment.

8. Limites Restantes

- Le raffinement du seuil améliore le rappel (recall) au prix de la précision — un usage en production nécessiterait un arbitrage formalisé avec le management clinique sur le coût réel d'un faux positif (rappel superflu) versus un faux négatif (créneau perdu).

- Le test d'erreur par segment repose sur le même échantillon de test qu'en Semaine 6 (25% du dataset, 1185 rendez-vous) — une validation croisée (k-fold) apporterait une confirmation plus robuste avant la présentation finale.
- La heatmap combinée conserve des cellules à faible effectif dans les tranches extrêmes (délai très court ou très long combiné à un historique élevé) — un dataset plus volumineux serait nécessaire pour les fiabiliser complètement.

9. Recommandations pour la Semaine 8

4. Présenter le cycle complet de test (KPIs validés → anomalie investiguée → modèle raffiné) comme preuve de rigueur analytique dans la présentation finale.
5. Documenter le compromis précision/rappel du seuil 0,40 dans un format accessible au management non-technique, pour la décision finale d'adoption.
6. Si le temps le permet, valider le raffinement du seuil par validation croisée plutôt que sur un seul split train/test.