

AnalystLab Africa - Experience Lab

Initial HealthConnect Analytics Report

Exploratory Analysis, KPI Development & Business Insights

Piste : Data Analytics - Semaine 5

1. Revue de la Fondation Semaine 4

Le problème défini en Semaine 4 était de comprendre les facteurs associés aux rendez-vous manqués (no-shows) à HealthConnect Clinic. L'inspection initiale avait révélé un taux de no-show de 48,46% et identifié 5 KPIs potentiels liés à 6 questions business. Les ressources utilisées restent le dataset HealthConnect_Appointment_Data.csv (5 000 rendez-vous, 18 variables) et son Data Dictionary. La principale limite identifiée concernait l'interprétation des valeurs manquantes sur reminder_channel (27,32%), hypothèse désormais confirmée (voir Section 2).

2. Préparation des Données

Le dataset original (HealthConnect_Appointment_Data_original.csv) n'a pas été modifié. Une version nettoyée a été sauvegardée séparément sous HealthConnect_Appointment_Data_cleaned.csv, documentée ci-dessous.

Dimensions	5 000 lignes × 18 colonnes
Doublons (lignes / appointment_id)	0 / 0
Valeurs incohérentes	0 (previous_no_shows ≤ previous_appointments toujours vérifié ; aucun délai négatif)

2.1 Traitement des valeurs manquantes

- reminder_channel (1 366 valeurs manquantes, 27,32%) : confirmé structurel coïncide exactement avec reminder_sent = 'No' (1 366 cas). Recodé en catégorie explicite 'No Reminder Sent' plutôt que supprimé ou imputé, conformément à la note du Data Dictionary ('None when no reminder was sent').
- distance_to_clinic_km (90 valeurs manquantes, 1,80%) : imputé par la médiane, volume marginal sans impact significatif attendu sur les résultats agrégés.
- waiting_time_minutes (60 valeurs manquantes, 1,20%) : imputé par la médiane, même traitement que ci-dessus.

2.2 Répartition de la variable cible

Attended	2 314 (46,28%)
No-Show	2 423 (48,46%)
Cancelled	263 (5,26%)

Décision méthodologique : les analyses de taux de no-show ci-après excluent les rendez-vous annulés (Cancelled), afin de mesurer le taux de no-show réel parmi les rendez-vous où une présence était encore attendue (Attended + No-Show = 4 737 rendez-vous). Sur cette base, le taux de no-show s'établit à 51,15%.

3. Analyse Exploratoire (EDA)




Figure 1 : Répartition des résultats de rendez-vous

Près de la moitié des rendez-vous planifiés (48,46%) se soldent par un no-show, contre 46,28% de présences effectives et seulement 5,26% d'annulations formelles. Le faible taux d'annulation suggère que les patients qui ne peuvent honorer leur rendez-vous ne préviennent généralement pas la clinique, un no-show est donc rarement anticipé.

L'exploration de facteurs secondaires (type de rendez-vous, jour de la semaine, créneau horaire, genre, tranche d'âge, temps d'attente) n'a révélé aucune variation significative du taux de no-show (écarts inférieurs à 6 points de pourcentage dans tous les cas, sans gradient clair). Ces facteurs ne sont donc pas retenus comme KPIs prioritaires. L'analyse se concentre sur les 4 facteurs présentant un signal fort, détaillés en Section 4.

4. Développement des KPIs (résultats calculés)

Conformément aux 5 KPIs potentiels identifiés en Semaine 4, les 4 KPIs suivants ont été calculés en priorité, sur la base du signal observé lors de l'analyse exploratoire. Le tableau ci-dessous résume les résultats ; le détail de chaque KPI suit.

KPI	Résultat Clé	Question Business	Signal
Taux de No-Show Global	48,46% (51,15% hors annulations)	Ampleur du problème	Élevé
No-Show par Canal de Rappel	SMS 48,0% vs Aucun rappel 54,6%	Le rappel réduit-il le no-show ?	Modéré
No-Show par Délai de Réservation	29,5% (0-7j) → 71,4% (46-60j)	Le délai influence-t-il le no-show ?	Très fort
No-Show par Historique de No-Shows	46,3% (0) → 70,3% (3+)	Le passé prédit-il le futur ?	Très fort
No-Show par Distance à la Clinique	48,7% (0-5km) → 70,0% (30-50km)	La distance est-elle un frein ?	Fort

4.1 KPI — Taux de No-Show par Canal de Rappel

Définition : proportion de rendez-vous en no-show, ventilée par canal de rappel utilisé (SMS, Email, WhatsApp, ou aucun rappel envoyé). Pertinence : ce KPI répond directement à la question « L'envoi d'un rappel réduit-il le risque de no-show, et quel canal est le plus efficace ? », une information directement actionnable pour la clinique.




Figure 2 : Taux de No-Show par canal de rappel

Le SMS est le canal le plus efficace (48,0% de no-show) et l'absence de rappel affiche le taux le plus élevé (54,6%). L'écart global reste toutefois modéré (6,6 points), et WhatsApp (52,7%) est presque aussi peu efficace que l'absence de rappel, ce canal mérite d'être questionné plutôt que systématisé.

4.2 KPI — Taux de No-Show par Délai de Réservation

Définition : proportion de rendez-vous en no-show, ventilée par tranche de délai entre la date de réservation et la date du rendez-vous (booking_lead_days). Pertinence : répond à la question « Un délai de réservation plus long est-il associé à un risque de no-show plus élevé ? ».




Figure 3 : Taux de No-Show par délai de réservation

C'est le signal le plus fort observé dans l'ensemble de l'analyse : le taux de no-show passe de 29,5% pour les rendez-vous pris moins de 7 jours à l'avance à 71,4% pour ceux pris 46 à 60 jours à l'avance avec un écart de 41,9 points de pourcentage, avec une progression parfaitement monotone.

4.3 KPI : Taux de No-Show par Historique de No-Shows du Patient

Définition : proportion de rendez-vous en no-show, ventilée par nombre de no-shows précédents du patient (previous_no_shows). Pertinence : répond à la question « Le comportement passé du patient prédit-il son comportement futur ? ».




Figure 4 : Taux de No-Show par historique de no-shows

Deuxième signal le plus fort : le taux de no-show progresse de 46,3% pour les patients sans historique de no-show à 70,3% pour ceux en ayant déjà 3 ou plus. La relation est monotone et confirme la valeur prédictive de l'historique patient.

4.4 KPI : Taux de No-Show par Distance à la Clinique

Définition : proportion de rendez-vous en no-show, ventilée par tranche de distance domicile-clinique (distance_to_clinic_km). Pertinence : répond à la question « La distance à la clinique constitue-t-elle un frein à l'assiduité ? ».




Figure 5 : Taux de No-Show par distance à la clinique

Un gradient clair et régulier est observé : de 48,7% pour les patients à moins de 5 km à 70,0% pour ceux à plus de 30 km. Bien que ce sous-groupe représente un faible volume (70 rendez-vous), la tendance est cohérente avec l'intuition métier et mérite d'être surveillée.

5. Insights Business (5 insights clés)

1. Le délai de réservation est le facteur le plus déterminant du no-show : le risque de non-présentation quasi-triple (29,5% → 71,4%) entre un rendez-vous pris à moins d'une semaine et un rendez-vous pris à 46-60 jours, bien plus qu'aucun autre facteur analysé.
2. L'historique du patient est un signal prédictif fort et exploitable immédiatement : un patient ayant déjà 3 no-shows ou plus a 70,3% de risque de récidiver, contre 46,3% pour un patient sans antécédent, un ciblage prioritaire évident pour toute action corrective.
3. Les rappels réduisent le no-show, mais modestement et de façon inégale selon le canal : le SMS (48,0%) surpasse l'absence de rappel (54,6%) de 6,6 points, mais WhatsApp (52,7%) n'apporte quasiment aucun bénéfice par rapport à ne rien envoyer du tout.
4. La distance à la clinique freine l'assiduité de façon progressive : le taux de no-show augmente régulièrement avec la distance, jusqu'à 70,0% au-delà de 30 km, suggérant un besoin de solutions à distance pour les patients éloignés.

5. Les facteurs démographiques et logistiques classiques (genre, âge, jour, créneau horaire, type de rendez-vous) n'expliquent pas le no-show à HealthConnect : leurs écarts sont faibles et sans tendance claire, ce qui recentre l'action sur les 4 leviers ci-dessus plutôt que sur une segmentation démographique.

6. Recommandations Business

1. Plafonner ou fractionner les délais de réservation longs. Pour les rendez-vous non urgents nécessitant un délai supérieur à 30 jours, envisager un rappel de confirmation intermédiaire (à mi-délai) plutôt qu'un unique rappel proche de la date, afin de contrer l'effet d'éloignement temporel identifié comme facteur n°1.
2. Prioriser le SMS comme canal de rappel par défaut : Migrer progressivement les rappels WhatsApp vers SMS, dont l'efficacité relative est confirmée ; réévaluer l'utilité de WhatsApp dans ce contexte.
3. Mettre en place un suivi renforcé pour les patients à historique de no-show : Un simple signal dans le système de prise de rendez-vous (2+ no-shows précédents) pourrait déclencher un appel de confirmation personnalisé plutôt qu'un rappel automatisé standard.
4. Étudier des options de téléconsultation pour les patients à plus de 20 km : Le sous-groupe à distance élevée, bien que restreint en volume, affiche le risque le plus élevé après le délai de réservation et l'historique.
5. Ne pas prioriser de segmentation par genre, âge ou créneau horaire : Ces facteurs n'apportent pas de signal exploitable à ce stade ; les ressources doivent se concentrer sur les 4 leviers confirmés.

7. Limites de l'Analyse

- Analyse corrélationnelle uniquement : les relations observées (délai, historique, distance) ne démontrent pas de causalité directe et devront être confirmées par une approche de modélisation (piste Data Science).
- Le sous-groupe 'distance 30-50km' repose sur seulement 70 observations, ce qui limite la robustesse statistique de ce résultat spécifique malgré sa cohérence apparente.
- Le dataset est fictif et anonymisé ; le taux de no-show de 48,46% dépasse largement les standards sectoriels réels (10-30%), ce qui peut refléter un choix de conception pédagogique plutôt qu'une situation strictement réaliste.
- Les rendez-vous annulés (Cancelled, 5,26%) ont été exclus du calcul des taux de no-show ; un patient qui annule tardivement sans réattribution du créneau a un impact opérationnel proche d'un no-show, ce qui n'est pas capturé ici.

8. Collaboration Inter-Pistes

Piste concernée : Data Science.

Information échangée : les 4 KPIs calculés dans ce rapport (délai de réservation, historique de no-shows, canal de rappel, distance à la clinique) constituent les variables présentant le signal le plus fort avec la variable cible `appointment_outcome`, sur la base d'une analyse bivariée simple.

Pertinence : ces résultats orientent directement le choix des features prioritaires pour le modèle de prédiction de no-show que la piste Data Science doit construire en Semaine 5, en évitant de disperser l'effort de modélisation sur des variables démographiques peu discriminantes (genre, âge, jour, créneau horaire) identifiées comme non pertinentes dans ce rapport.

Bénéfice attendu : un gain de temps pour la piste Data Science, qui peut prioriser l'ingénierie de features autour de booking_lead_days, previous_no_shows, distance_to_clinic_km et reminder_channel plutôt que d'explorer l'ensemble des 18 variables sans hiérarchisation préalable.