

Week 5 Project Summary

HealthConnect Clinic - Data Analytics Track

1. Objectif prévu pour la Semaine 5

Passer de la compréhension du problème (Semaine 4) à une analyse concrète : préparer les données, mener une analyse exploratoire, calculer 3 à 5 KPIs parmi ceux identifiés précédemment, produire des visualisations, et formuler au moins 5 insights business exploitables.

2. Ce qui a été réalisé

- Préparation des données : dataset original préservé, version nettoyée sauvegardée séparément (recodage de `reminder_channel`, imputation médiane sur `distance_to_clinic_km` et `waiting_time_minutes`).
- Analyse exploratoire complète : variable cible, facteurs secondaires (démographie, jour, créneau, type de RDV) écartés faute de signal significatif.
- 4 KPIs calculés et interprétés : canal de rappel, délai de réservation, historique de no-shows, distance à la clinique chacun relié à sa question business et illustré par une visualisation dédiée.
- 5 insights business formulés, avec 5 recommandations opérationnelles associées.
- Limites de l'analyse documentées, et point de collaboration inter-pistes avec Data Science formalisé.

3. Principaux résultats

Le délai de réservation est le facteur le plus déterminant identifié (29,5% de no-show à moins de 7 jours contre 71,4% au-delà de 45 jours), suivi de près par l'historique de no-shows du patient (46,3% à 70,3% selon le nombre de no-shows antérieurs). L'effet des rappels est réel mais modeste, et très dépendant du canal utilisé (le SMS surpasse nettement WhatsApp). La distance à la clinique confirme un effet progressif, bien que basé sur un sous-échantillon plus restreint pour les plus longues distances.

4. Difficultés rencontrées

- La distinction entre valeur manquante et valeur structurellement absente sur `reminder_channel` nécessitait une vérification croisée avec `reminder_sent` avant tout traitement : un recodage naïf (suppression ou imputation par le mode) aurait faussé l'analyse du KPI associé.
- Le sous-groupe de patients à distance supérieure à 30 km est de taille réduite (70 rendez-vous), ce qui limite la confiance statistique à accorder à ce résultat spécifique malgré sa cohérence avec la tendance générale.

5. Décisions prises et justification

- Exclusion des rendez-vous annulés (Cancelled) du calcul des taux de no-show, afin de mesurer un taux de no-show réel parmi les rendez-vous où une présence était encore attendue, ceci fait passer le taux de référence de 48,46% à 51,15%, une nuance importante à documenter pour la cohérence avec les analyses futures.

- Priorisation de 4 KPIs sur les 5 identifiés en Semaine 4 (le taux de no-show global n'étant pas recompté séparément mais intégré comme point de référence), conformément à la fourchette 3-5 KPIs demandée.

6. Changements par rapport à l'approche Semaine 4

Aucun changement de fond : l'approche annoncée en Semaine 4 (nettoyage ciblé, analyse univariée puis bivariée, priorisation des facteurs) a été suivie telle quelle. La seule précision apportée est la décision d'exclure les rendez-vous annulés du dénominateur des taux de no-show, un choix méthodologique qui n'avait pas été explicitement anticipé en Semaine 4.

7. Collaboration inter-pistes réalisée

Transmission à la piste Data Science des 4 facteurs présentant le signal le plus fort avec le no-show (délai de réservation, historique de no-shows, canal de rappel, distance à la clinique), afin d'orienter la sélection des features pour le modèle prédictif de la Semaine 5, en écartant les variables démographiques peu discriminantes identifiées dans ce rapport.

8. Travail restant

- Approfondir l'analyse du KPI distance avec un échantillon élargi si de nouvelles données deviennent disponibles.
- Construire un dashboard interactif (Power BI) reprenant ces analyses pour une consultation autonome par le management de la clinique.
- Évaluer l'interaction entre plusieurs facteurs combinés (ex : délai long ET historique de no-shows) plutôt que des analyses univariées isolées.

9. Focus proposé pour la Semaine 6

Construction d'un dashboard interactif consolidant les 4 KPIs validés, avec filtres (type de rendez-vous, tranche de distance, canal de rappel), et première exploration des interactions entre facteurs combinés pour affiner le ciblage des patients à haut risque de no-show.