

Week 6 Project Summary

HealthConnect Clinic - Data Analytics Track

1. Objectif prévu

Ne pas répéter l'EDA de la Semaine 5, mais approfondir et valider statistiquement les deux findings les plus forts (délai de réservation, historique de no-shows), analyser leurs effets combinés, et réaliser une véritable intégration cross-track avec preuve à l'appui.

2. Ce qui a été réalisé

- Validation statistique par test du Chi² des 3 KPIs principaux : délai de réservation ($p < 0,0001$), historique de no-shows ($p < 0,0001$), canal de rappel ($p = 0,0019$).
- Analyse de l'effet combiné délai $\times$ historique (heatmap croisée) : confirmation d'un effet cumulatif allant jusqu'à 91% de no-show sur le pire profil combiné.
- Construction d'une segmentation de risque actionnable à 4 niveaux (Low/Medium/Medium/High Risk), isolant 977 rendez-vous (20,6% du volume) à taux de no-show de 70,5%.
- Validation de robustesse : l'effet du délai de réservation se vérifie de façon cohérente dans les 4 types de rendez-vous, écartant l'hypothèse d'un artefact localisé.
- Intégration cross-track réalisée concrètement : construction d'un modèle de régression logistique (rôle Data Science auto-assumé, faute de binôme) utilisant les 4 KPIs validés, avec évaluation complète (accuracy, precision, recall, F1, ROC-AUC, matrice de confusion).

3. Ce qui a été amélioré par rapport à la Semaine 5

- Passage d'une analyse purement descriptive à une analyse statistiquement validée (tests de significativité).
- Passage d'une analyse univariée (un facteur à la fois) à une analyse des effets combinés, plus fidèle à la réalité opérationnelle.
- Passage d'un ensemble de KPIs séparés à une segmentation de risque unique, directement actionnable pour cibler les interventions.
- Passage d'une simple intention de collaboration à une preuve d'intégration concrète (modèle entraîné et évalué).

4. Intégration réalisée

Piste : Data Science (auto-assumée, absence de binôme réel dans cette cohorte solo). Échange : transmission des 4 KPIs validés comme features ; en retour (rôle simulé), un modèle de classification a été construit et évalué pour tester leur valeur prédictive réelle. Résultat : +11,3 points d'accuracy par rapport à une baseline naïve, confirmant que les KPIs Data Analytics constituent une base de features solide pour un futur modèle de production.

5. Principaux résultats

Le résultat le plus significatif est la confirmation que le délai de réservation et l'historique de no-shows ne sont pas de simples corrélations isolées : ils sont statistiquement très significatifs, se combinent de façon cumulative (jusqu'à 91% de no-show sur le profil combiné le plus à risque), et restent valides dans tous les types de rendez-vous testés. La preuve d'intégration confirme en outre leur valeur prédictive réelle au-delà de l'analyse descriptive.

6. Difficultés rencontrées

- L'absence de binôme réel sur la piste Data Science a nécessité de repenser la nature de l'intégration cross-track : plutôt que de simuler un faux échange, le choix a été fait de produire un véritable artefact de modélisation, solution plus rigoureuse mais plus chronophage.
- La cellule '0-7 jours × 3+ no-shows' de la heatmap combinée (23%, contre-intuitive) a nécessité une vérification de taille d'échantillon (n=13) pour écarter une fausse alerte dans l'interprétation.

7. Décisions importantes

- Décision de construire un vrai modèle prédictif plutôt que de se limiter à une documentation d'intention, afin de satisfaire l'exigence explicite du cahier des charges qu'une simple communication ne suffit pas comme preuve d'intégration.
- Décision de limiter le modèle de validation à 4 features (celles déjà validées), plutôt que d'explorer l'ensemble des 18 variables — cohérent avec l'objectif de tester la valeur des KPIs Data Analytics, non de construire le modèle final (responsabilité Data Science).

8. Problèmes non résolus

- Le pouvoir prédictif du modèle de validation reste modéré (ROC-AUC 0,665) — des variables non présentes dans ce dataset pourraient améliorer sensiblement un futur modèle de production.
- La stabilité de la segmentation de risque à 4 niveaux n'a pas été testée sur une période distincte (à faire en Semaine 7).

9. Contribution au projet HealthConnect global

Cette semaine transforme les findings descriptifs de la Semaine 5 en un double livrable directement exploitable par la clinique (segmentation de risque opérationnelle) et par la piste Data Science (validation empirique de la valeur prédictive des features), incarnant concrètement la logique d'intégration attendue en Semaine 6.

10. Focus proposé pour la Semaine 7

Tester la stabilité de la segmentation de risque sur un sous-échantillon distinct, évaluer l'ajout de features d'interaction (ex : distance × délai) dans le modèle de validation, et valider avec une perspective Project Management la faisabilité opérationnelle de l'alerte par profil de risque avant la présentation finale.